

Predição do Ganho Médio Diário de Peso em Bovinos de Corte via Redes Neurais Artificiais

Seminário de Qualificação de TCC

Euler Gomes da Rocha
eulergomesrocha@gmail.com

Bacharelado em Engenharia de Computação
Orientador: Prof. Dr. Ciniro Aparecido Leite Nametala
Coorientadora: Dra. Tamires Martins Rezende
2026



Sumário

- 1 Introdução
 - Contextualização
 - Objetivos
 - Justificativa
 - Classificação da pesquisa
- 2 Referencial Teórico
 - Revisão Bibliográfica
 - Fundamentação Teórica
- 3 Metodologia
- 4 Análise Exploratória
- 5 Considerações Parciais
- 6 Referências

Introdução – Contextualização

- Pecuária de corte: o Brasil é um dos maiores produtores e exportadores mundiais (United States Department of Agriculture, 2026). O agronegócio fechou 2025 com exportações recordes de US\$ 169 bi e superávit de US\$ 149 bi (Ministério da Agricultura e Pecuária, 2026).

- O Ganho Médio Diário (GMD) é um dos principais indicadores de desempenho produtivo – o acréscimo médio de peso corporal por dia de avaliação (EMBRAPA, 2026):

$$GMD = (\text{peso_atual} - \text{peso_anterior}) / \text{dias_entre_pesagens}$$

- Sua predição é complexa: resulta da interação de múltiplos fatores – genéticos, nutricionais, sanitários, climáticos e de manejo (Tambara *et al.*, 2021; Faria; Martins; Freitas, 2025; Alencastro Filho *et al.*, 2017).
- Redes Neurais Artificiais (RNA) modelam relações não lineares a partir de dados históricos (Silva; Spatti; Flauzino, 2016; Goodfellow; Bengio; Courville, 2016).

Introdução – Objetivos

Objetivo Geral

Desenvolver e validar um modelo de Rede Neural Artificial (MLP) para a predição do GMD em bovinos de corte da microrregião de Bambuí-MG, a partir de variáveis zootécnicas, nutricionais, sanitárias, climáticas e de manejo, classificando os animais em categorias de desempenho produtivo com base nas estimativas obtidas.

Objetivos Específicos

- 1 Coletar e consolidar os dados das propriedades rurais
- 2 Realizar o pré-processamento e a análise exploratória dos dados
- 3 Desenvolver e treinar o modelo de RNA (MLP) para predição do GMD
- 4 Converter as estimativas de GMD em categorias de desempenho produtivo
- 5 Avaliar o desempenho do modelo por métricas estatísticas (MSE, RMSE, MAE)


Introdução – Justificativa

- O GMD é um dos principais indicadores de desempenho na pecuária de corte (Alencastro Filho *et al.*, 2017), mas sua predição é complexa e os modelos tradicionais têm limitações na captura de relações não lineares (Faria; Martins; Freitas, 2025).
- As RNAs permitem modelar essas relações com maior precisão (Silva; Spatti; Flauzino, 2016; Goodfellow; Bengio; Courville, 2016).
- **Lacuna:** em pesquisa preliminar na base Scopus, não foram encontrados trabalhos com esse recorte regional e essa combinação de variáveis.
- **Diferencial:** integra variáveis zootécnicas, sanitárias, climáticas e de manejo obtidas por registros de rotina – sem dependência de equipamentos de alto custo (câmeras/sensores).
- **Aplicação:** ferramenta de apoio à decisão acessível a produtores de pequeno e médio porte.

Introdução – Classificação da pesquisa

- Natureza: Aplicada, uma vez que tem como objetivo o desenvolvimento de uma solução tecnológica com aplicação prática no contexto da pecuária de corte.
- Abordagem: Quantitativa, uma vez que se baseia na análise de dados numéricos e na aplicação de técnicas estatísticas e computacionais para modelagem e predição do fenômeno estudado.
- Objetivo: Explicativo, pois busca identificar e compreender as relações entre variáveis zootécnicas, ambientais e de manejo que influenciam o ganho de peso dos bovinos.
- Procedimento: Experimental, visto que envolve a construção, treinamento e avaliação de modelos de aprendizado de máquina, com a realização de testes controlados para análise de desempenho.

Revisão Bibliográfica – Bibliometria



- Busca no **Scopus** (2018+) sobre ML aplicado à pecuária bovina: **172 documentos**, com crescimento e pico de 56 artigos em 2025.

Trabalhos Relacionados e Posicionamento

- **Tuyishime & Adewusi (2025)** (Tuyishime; Adewusi, 2025) – predição do ganho de peso com variáveis zootécnicas, ambientais e de manejo; *sem* variáveis sanitárias nem classificação.
- **Grzesiak et al. (2023)** (Grzesiak *et al.*, 2023) – classificação do GMD em categorias, porém com dados de linhagem materna (laboratoriais).
- **Bauer & Jagusiak (2022)** (Bauer; Jagusiak, 2022) – MLP com retropropagação sobre variáveis sanitárias; valida a arquitetura adotada.

■ Diferencial deste trabalho

Integra variáveis zootécnicas, **sanitárias**, climáticas e de manejo em um único modelo, com **dados de rotina** (sem câmeras/sensores) e classificação sem dados genômicos – no recorte inédito de **BambuÍ-MG**.

Redes Neurais Artificiais (MLP)

- RNAs são modelos inspirados no sistema nervoso biológico: neurônios organizados em camadas e interligados por conexões ponderadas (McCulloch; Pitts, 1943; Rosenblatt, 1958).
- Cada neurônio combina entradas e aplica uma função de ativação (Silva; Spatti; Flauzino, 2016):

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right)$$

- *Multilayer Perceptron* (MLP): camada de entrada (13 variáveis) → camadas ocultas (transformações não lineares) → saída com 1 neurônio linear (Goodfellow; Bengio; Courville, 2016).
- Ativação **ReLU** nas camadas ocultas ($f(x) = \max(0, x)$); saída **linear**, adequada ao GMD contínuo.
- Treinamento por retropropagação do erro e otimizador **Adam**.

Métricas de Avaliação

Regressão (GMD contínuo)

- **MSE** – penaliza fortemente erros grandes; sensível a outliers
- **RMSE** – mesma unidade do GMD (kg/dia); mais interpretável
- **MAE** – erro médio absoluto; menos sensível a outliers

Classificação de desempenho

- GMD contínuo convertido em **3 classes**: baixo, médio e alto
- Limites por **quantis empíricos** (tercis: percentis 33,3% e 66,7%) → classes balanceadas
- Limiares estimados só no treino (evita vazamento)
- Métricas: **acurácia** e **F1-score**

Variáveis do Conjunto de Dados

13 variáveis preditoras em 5 grupos temáticos + variável-alvo:

- **Animal (3):** peso inicial, idade, proporção *Bos indicus*
- **Nutrição/pastagem (5):** suplemento (quantidade, PB, EM), PB e digestibilidade da forragem
- **Manejo (1):** estresse por transporte
- **Clima (2):** temperatura média, precipitação acumulada
- **Sanidade (2):** dias desde e duração do último evento sanitário
- **Alvo:** GMD (kg/dia)

Excluídas: 5 variáveis de variância nula (condições homogêneas de manejo) e `dias_permanencia` – denominador do GMD, removida para evitar vazamento de informação.

Metodologia – Coleta de Dados

- Duas propriedades rurais da microrregião de **Bambuí-MG**, com autorização dos proprietários.
- Pesagens realizadas entre **2021 e 2026**; cada amostra corresponde a uma pesagem individual de um animal.
- Registros de controle interno transcritos para um formulário estruturado (**Google Forms**).
- Conjunto final: **494 amostras**.
- Limitações reconhecidas: independência das amostras (brinco reaproveitado entre animais) e leves variações de protocolo entre as fazendas.

Metodologia – Pré-processamento e Variáveis

Derivação automática

- GMD (alvo) pela fórmula do ganho
- Nutrição via tabelas **CQBAL**
- Clima via API **NASA POWER**
(temperatura e precipitação)

Tratamento e seleção


- Inconsistências, normalização e codificação de binárias
- Seleção por **literatura zootécnica**
- Remoção das 5 variáveis de variância nula e de dias_permanencia (vazamento)

Ferramentas: Python, Pandas, PyTorch e Jupyter Notebook.

Análise Exploratória – Visão Geral


- Conjunto de **494 amostras** e 20 variáveis, **sem valores ausentes** (coleta estruturada por formulário).
- 5 variáveis com valor **constante** (somente fêmeas, suplementação diária, pastejo rotacionado, sem vacinação/vermifugação recentes) – mantidas fora dos preditores.
- Objetivo: caracterizar a variável-alvo e as preditoras *antes* da modelagem.

Distribuição do Ganho Médio Diário




- Média 0,341 e mediana 0,345 kg/dia.
- Valores negativos indicam perda de peso – plausível a pasto na estação seca.
- Justifica definir as categorias por **quantis** (tercis), garantindo classes balanceadas.

Matriz de Correlação



Multicolinearidade entre preditoras (ex.: PB e energia metabolizável; PB e digestibilidade da forragem).

Correlação das Variáveis com o GMD



- Todas as correlações lineares com o alvo são **fracas** ($|r| < 0,26$).
- Nenhuma variável isolada explica o GMD linearmente.

Considerações Parciais e Próximos Passos

■ Constatações

- Boa qualidade estrutural (sem faltantes; variáveis problemáticas identificadas)
- Alvo assimétrico com valores negativos
→ categorias por quantis
- Correlações fracas + multicolinearidade

■ Próximos passos

- Treinamento e validação da MLP (busca de hiperparâmetros)
- Avaliação (MSE, RMSE, MAE) e classificação em categorias
- Ampliação da base com novas propriedades

Referências I

ALENCASTRO FILHO, A. d. *et al.* Ganho em peso médio diário de diferentes grupos genéticos de bovinos de corte. **Pubvet**, v. 11, n. 1, p. 87–90, 2017. DOI: 10.22256/pubvet.v11n1.87-90.

BAUER, E. A.; JAGUSIAK, W. The use of multilayer perceptron artificial neural networks to detect dairy cows at risk of ketosis. **Animals**, MDPI, v. 12, n. 3, p. 332, 2022. Acesso aberto (CC BY). DOI: 10.3390/ani12030332. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8833383/>.

EMBRAPA. **Ganho de peso para tratamento seletivo**. 2026. Disponível em: <https://www.embrapa.br/paratec-controle-integrado-verminoses/vermes/caprinos-ovinos/ganho-peso-para-tratamento-seletivo>. Acesso em: 01 abr. 2026.

FARIA, R. I. d.; MARTINS, J. A. R.; FREITAS, J. C. d. Influência dos minerais orgânicos e melhoramento genético no GMD (Ganho Médio Diário) de bovinos em sistema de confinamento. v. 5, 2025.

Referências II

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge, MA, USA: MIT Press, 2016. Disponível em: <http://www.deeplearningbook.org>.

GRZESIAK, W. *et al.* Classification of daily body weight gains in beef calves using decision trees, artificial neural networks, and logistic regression. **Animals**, MDPI, v. 13, n. 12, p. 1956, 2023. Acesso aberto (CC BY). DOI: 10.3390/ani13121956. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC10295584/>.

MCCULLOCH, W. S.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **The Bulletin of Mathematical Biophysics**, v. 5, n. 4, p. 115–133, 1943. DOI: 10.1007/BF02478259.

Referências III

MINISTÉRIO DA AGRICULTURA E PECUÁRIA. **Agronegócio brasileiro fecha 2025 com recorde em exportações de US\$ 169 bilhões e superávit de US\$ 149,07 bilhões.** 2026.

Disponível em:

<https://www.gov.br/agricultura/pt-br/assuntos/noticias/agronegocio-brasileiro-fecha-2025-com-recorde-em-exportacoes-de-us-169-bilhoes-e-superavit-de-us-149-07-bilhoes>. Acesso em: 01 abr. 2026.

ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. **Psychological Review**, v. 65, n. 6, p. 386–408, 1958. DOI: 10.1037/h0042519.

SILVA, I. N. d.; SPATTI, D. H.; FLAUZINO, R. A. **Redes neurais artificiais para engenharia e ciências aplicadas: fundamentos teóricos e aspectos práticos.** 2. ed. São Paulo: Artliber, 2016.

Referências IV

TAMBARA, A. A. C. *et al.* Effects of supplementation on production of beef cattle grazing tropical pastures in Brazil during the wet and dry seasons: a meta-analysis. **Revista Brasileira de Zootecnia**, Sociedade Brasileira de Zootecnia, v. 50, p. e20210020, 2021. Acesso aberto (CC BY). DOI: 10.37496/rbz5020210020. Disponível em: <https://rbz.org.br/article/effects-of-supplementation-on-production-of-beef-cattle-grazing-tropical-pastures-in-brazil-during-the-wet-and-dry-seasons-a-meta-analysis/>.

TUYISHIME, K.; ADEWUSI, M. A. Data-driven prediction of cattle weight gain for evaluating key growth factors with machine learning approaches. **Discover Computing**, Springer, v. 28, n. 1, p. 275, 2025. Acesso aberto (CC BY). DOI: 10.1007/s10791-025-09798-6. Disponível em: <https://link.springer.com/article/10.1007/s10791-025-09798-6>.

UNITED STATES DEPARTMENT OF AGRICULTURE. **Production | USDA Foreign Agricultural Service**. 2026. Disponível em: <https://www.fas.usda.gov/data/production>. Acesso em: 01 abr. 2026.

Obrigado

Favor enviar as sugestões e os pedidos de correção para eulergomesrocha@gmail.com.

